Санкт-Петербургский политехнический университет Петра Великого
Институт компьютерных наук и технологий
Высшая школа программной инженерии

Лабораторная работа №5

“Линейная регрессия”
по дисциплине “Машинное обучение”

Выполнил Лелюхин Д.О.
студент гр. 33504/2 _____

Руководитель Селин И.А.
_____

Санкт-Петербург
2018

Оглавление

Первое задание:

Загрузите данные из файла reglab1.txt. Используя функцию lm, постройте регрессию (используйте разные модели). Выберите наиболее подходящую модель, объясните свой выбор.

Код программы:

```
A <- read.table("reglab1.txt",  header = TRUE, sep = "\t")
data <- lm(z ~ ., data = A)
summary(data)
```

Результаты:

Для модели x:

```
Multiple R-squared:  0.9187,    Adjusted R-squared:  0.9178
F-statistic:  1113 on 2 and 197 DF, p-value: < 2.2e-16
```

Для модели y:

```
Multiple R-squared:  0.9505,    Adjusted R-squared:  0.95
F-statistic:  1893 on 2 and 197 DF, p-value: < 2.2e-16
```

Для модели z:

```
Multiple R-squared:  0.9686,    Adjusted R-squared:  0.9683
F-statistic:  3041 on 2 and 197 DF, p-value: < 2.2e-16
```

Выбираем модель z, т.к. коэффициенты детерминации у данной модели наиболее близки к 1 чем у других моделей.

Второе задание:

Реализуйте следующий алгоритм для уменьшения количества признаков, используемых для построения регрессии: для каждого $k \in \{0,1,\ldots,d\}$ выбрать подмножество признаков мощности k[1], минимизирующее остаточную сумму квадратов RSS. Используя полученный алгоритм, выберите оптимальное подмножество признаков для данных из файла reglab2.txt. Объясните свой выбор. Для генерации всех возможных сочетаний по m элементов из некоторого множества x можно использовать функцию combn(x, m, ...).

Код программы:

```
A <- read.table("reglab2.txt", header = TRUE, sep = "\t")
combination <- combn(A[, 2:5], 2)
for(i in 1:length(combination[1,]))
{
 tmp <- data.frame(A$y, combination[1, i], combination[2, i])
 res <- lm(tmp$A.y ~., data = tmp)
 print(sum((tmp$A.y - res$fitted.values)^2))
}
```

Результаты:

[1] 0.5379617
[1] 156.3541
[1] 157.2193
[1] 267.7955
[1] 267.8061
[1] 393.4587

По результатам видно, что минимальная RSS у первого столбца.

Третье задание:

Загрузите данные из файла cygage.txt. Постройте регрессию, выражающую зависимость возраста исследуемых отложений от глубины залегания, используя веса наблюдений. Оцените качество построенной модели.

Код программы:

```
A <- read.table("cygage.txt", header = TRUE, sep = "\t")
f <- lm(calAge~Depth, data=A, weights = A$Weight)
summary(f)
```

Результаты:

```
Multiple R-squared:  0.9737,  Adjusted R-squared:  0.9711
F-statistic:   370 on 1 and 10 DF, p-value: 3.141e-09
```

Коэффициенты детерминации близки к единице.

Четвертое задание:

Загрузите данные Longley (макроэкономические данные). Данные состоят из 7 экономических переменных, наблюдаемых с 1947 по 1962 годы (n=16):
GNP.deflator - дефлятор цен,
GNP - валовой национальный продукт,
Unemployed – число безработных
Armed.Forces – число людей в армии
Population – население, возраст которого старше 14 лет
Year – год
Employed – количество занятых

Построить регрессию lm(Employed ~ .) .

Исключите из набора данных longley переменную "Population". Разделите данные на тестовую и обучающую выборки равных размеров случайным образом. Постройте гребневую регрессию для значений $\lambda = 10^{-3+0.2i}$, $i = 0,\ldots,25$, подсчитайте ошибку на тестовой и обучающей выборке для данных значений λ, постройте графики. Объясните полученные результаты.

Код программы:

```
library(MASS)
library(datasets)
A<-longley
res <- lm(Employed ~., data = A)
summary(res)
A.1 <- A[,-5]
set.seed(12345)
n <- dim(A.1)[1]
A_rand <- A.1[ order(runif(n)), ]
A_train <- A_rand[1:(n/2),]
A_test <- A_rand[((n/2)+1):n,]
ml = c()
for (i in 1:25){
  ml <- c(ml, 10^(-3 + 0.2 * i))
}
res <- lm.ridge(Employed ~., data = A_train, lambda = ml)
plot(x=res$lambda, y=res$GCV, type="o")
lambda <- res$GCV[which.min(res$GCV)]
res <- lm.ridge(Employed ~., data = A_train, lambda = lambda)
print(res)
for(i in 1:25){
  res.test <- lm(Employed ~., data = A_train)
  res.error <- (res.test$fitted.values - A_train$Employed) ^ 2
  res <- lm.ridge(Employed ~., data = A_train, lambda = ml[i])
  res.error <- res.error + ml[i] * sum(abs(res$coef))
  print(res.error)
}
```

Результаты:

Построил регрессию lm(Employed~.)

```
Multiple R-squared:  0.9955,   Adjusted R-squared:  0.9925
F-statistic: 330.3 on 6 and 9 DF, p-value: 4.984e-10
```

Построил гребневую регрессию для значений $\lambda = 10^{-3+0.2i}$, $i = 0,\ldots,25$.

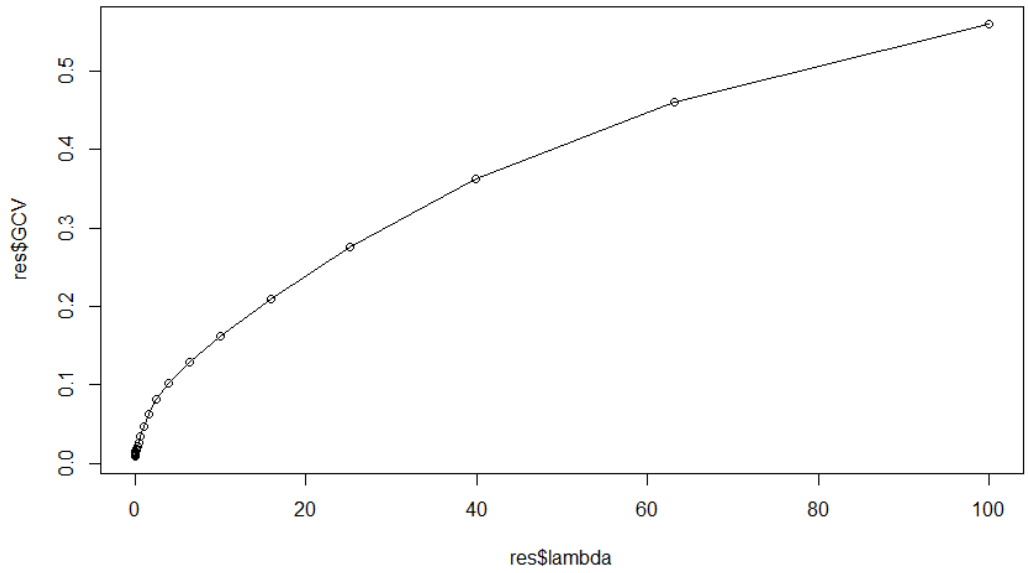

График зависимости критериев GCV от значений заданных лямбд. Оптимальное значение лямбды равно 0.00158.

Пятое задание:

Загрузите данные EuStockMarkets из пакета « datasets». Данные содержат ежедневные котировки на момент закрытия фондовых бирж: Germany DAX (Ibis), Switzerland SMI, France CAC, и UK FTSE. Постройте на одном графике все кривые изменения котировок во времени. Постройте линейную регрессию для каждой модели в отдельности и для всех моделей вместе. Оцените, какая из бирж имеет наибольшую динамику.

Код программы:

```
#Unit 5
library(datasets)
data("EuStockMarkets")
plot(EuStockMarkets)
for(i in 1:4){
  res <- lm(EuStockMarkets[,i]~., data = EuStockMarkets[,-i])
  print(res)
  print(summary(res))
  png(file = paste(toString(i),'lm.png'))
  plot(res)
  dev.off()
}
plot(EuStockMarkets[, 1], col = "red", ylab = "DAX SMI CAC FTSE")
lines(EuStockMarkets[, 2], col = "blue")
lines(EuStockMarkets[, 3], col = "green")
lines(EuStockMarkets[, 4], col = "yellow")
```

Результаты:

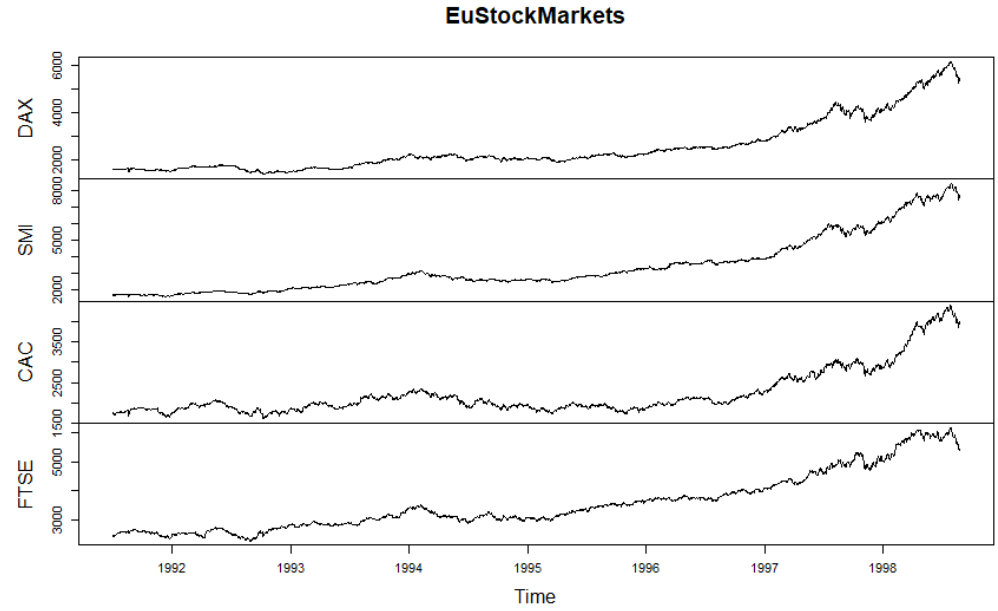

Линейные регрессии:

```
Multiple R-squared:  0.9898,   Adjusted R-squared:  0.9898
F-statistic: 6.032e+04 on 3 and 1856 DF, p-value: < 2.2e-16

Multiple R-squared:  0.9936,   Adjusted R-squared:  0.9936
F-statistic: 9.656e+04 on 3 and 1856 DF, p-value: < 2.2e-16

Multiple R-squared:  0.9484,   Adjusted R-squared:  0.9484
F-statistic: 1.138e+04 on 3 and 1856 DF, p-value: < 2.2e-16

Multiple R-squared:  0.9845,   Adjusted R-squared:  0.9845
F-statistic: 3.941e+04 on 3 and 1856 DF, p-value: < 2.2e-16
```

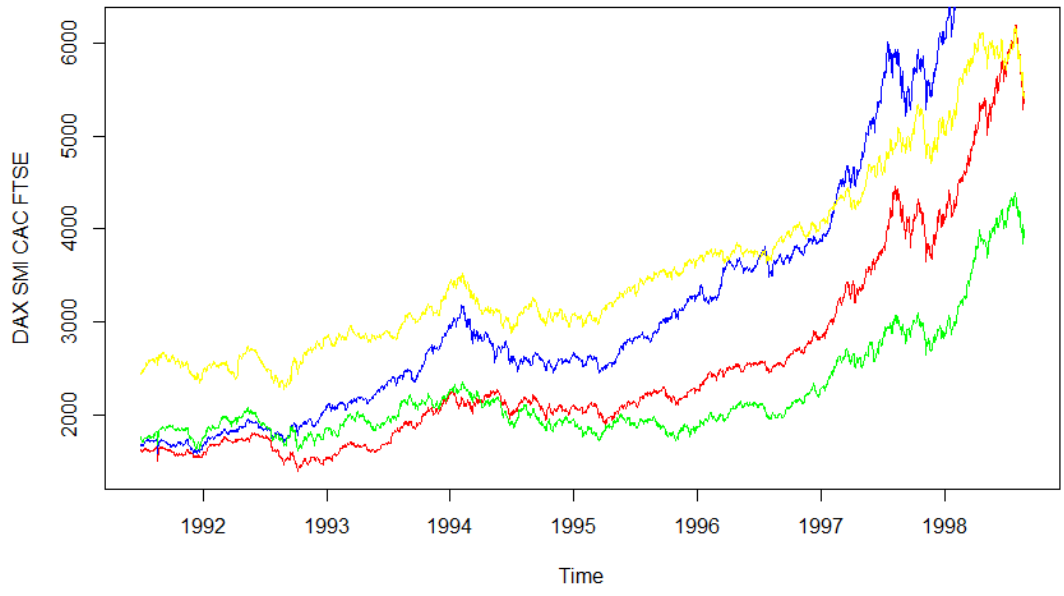

На графике видно, что SMI выглядит лучше, чем DAX, CAC, FTSE.

Шестое задание:

Загрузите данные JohnsonJohnson из пакета «datasets». Данные содержат поквартальную прибыль компании Johnson & Johnson с 1960 по 1980 гг. Постройте на одном графике все кривые изменения прибыли во времени. Постройте линейную регрессию для каждого квартала в отдельности и для всех кварталов вместе. Оцените, в каком квартале компания имеет наибольшую и наименьшую динамику доходности. Сделайте прогноз по прибыли в 2016 году во всех кварталах и в среднем по году.

Код программы:

```
library(datasets)
A <- JohnsonJohnson
plot(A)
i = 1
A.1 <- cbind(A[i], A[i+1], A[i+2], A[i+3])
i = 5
while(i < 84){
  myTmp <- cbind(A[i], A[i+1], A[i+2], A[i+3])
  A.1 <- rbind(A.1, myTmp)
  i <- i + 4
}
A.1 <- data.frame(A.1, 1960:1980)
res<-lm(X1+X2+X3+X4~X1960.1980, data = A.1)
res1 <- lm(X1~X1960.1980, data = A.1)
res2<-lm(X2~X1960.1980, data = A.1)
res3<-lm(X3~X1960.1980, data = A.1)
res4<-lm(X4~X1960.1980, data = A.1)
plot(res$fitted.values, x = (1960:1980))
lines(res1$fitted.values, col = "black", x = (1960:1980))
lines(res2$fitted.values, col = "blue", x = (1960:1980))
lines(res3$fitted.values, col = "green", x = (1960:1980))
lines(res4$fitted.values, col = "red", x = (1960:1980))

new<- data.frame(X1960.1980 = (2016))
pred <- predict(res1, newdata = new )
print(pred)
```

Результаты:

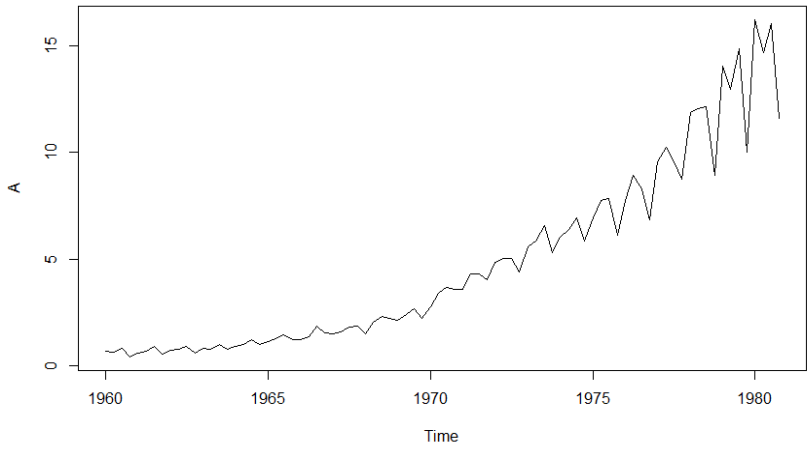

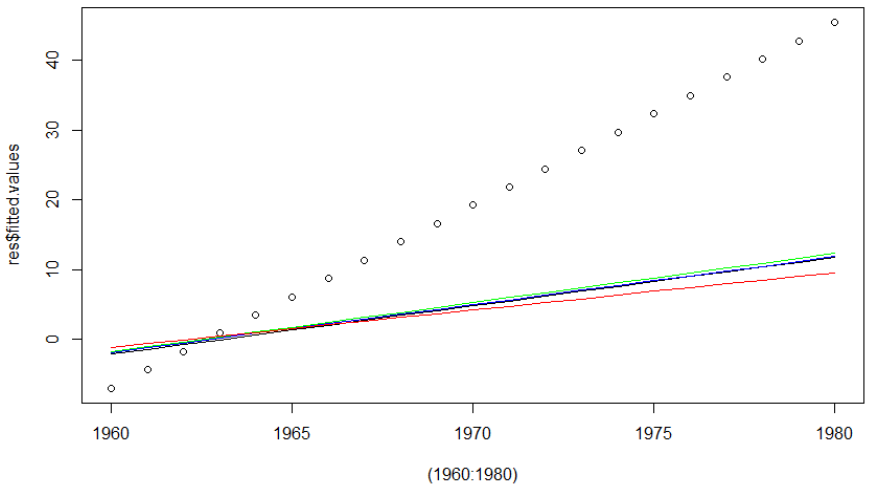

Прогноз на 2016 год:
1 квартал – 36.75964;
2 квартал – 36.48945;
3 квартал – 37.65394;
4 квартал – 28.79391;
год – 139.6969;

Лучший показатель у 3-го квартала, худший у 4-го.

Седьмое задание:

Загрузите данные sunspot.year из пакета «datasets». Данные содержат количество солнечных пятен с 1700 по 1988 гг. Постройте на графике кривую изменения числа солнечных пятен во времени. Постройте линейную регрессию для данных.

Код программы:

```
library(datasets)
A <- sunspot.year
plot(A)
A <- data.frame(A, Year=1700:1988)
res <- lm(A~Year, data = A)
plot(res$fitted.values)
```

Результаты:

Кривая изменения числа солнечных пятен во времени:

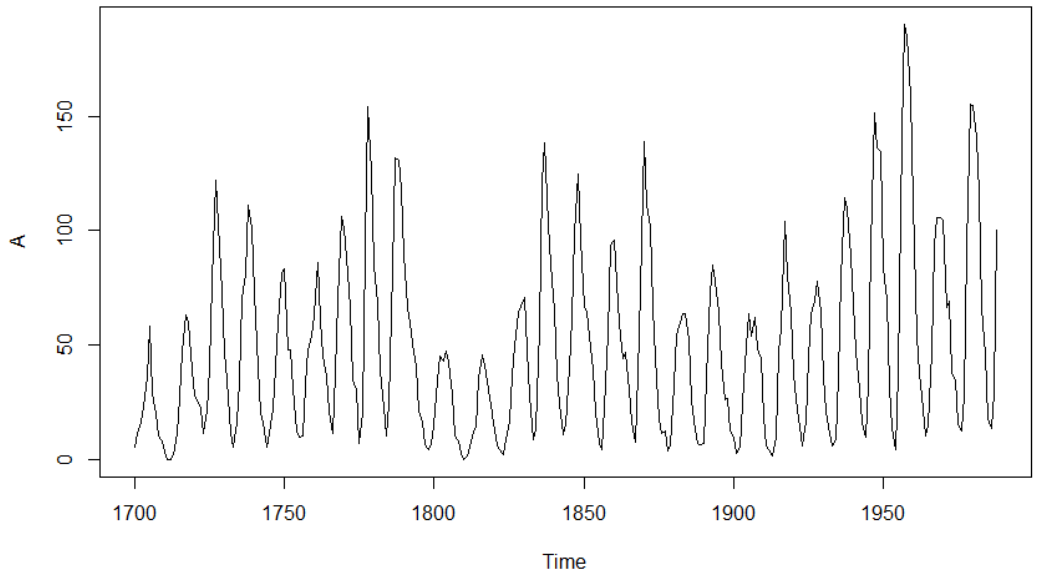

Линейная регрессия для данных:

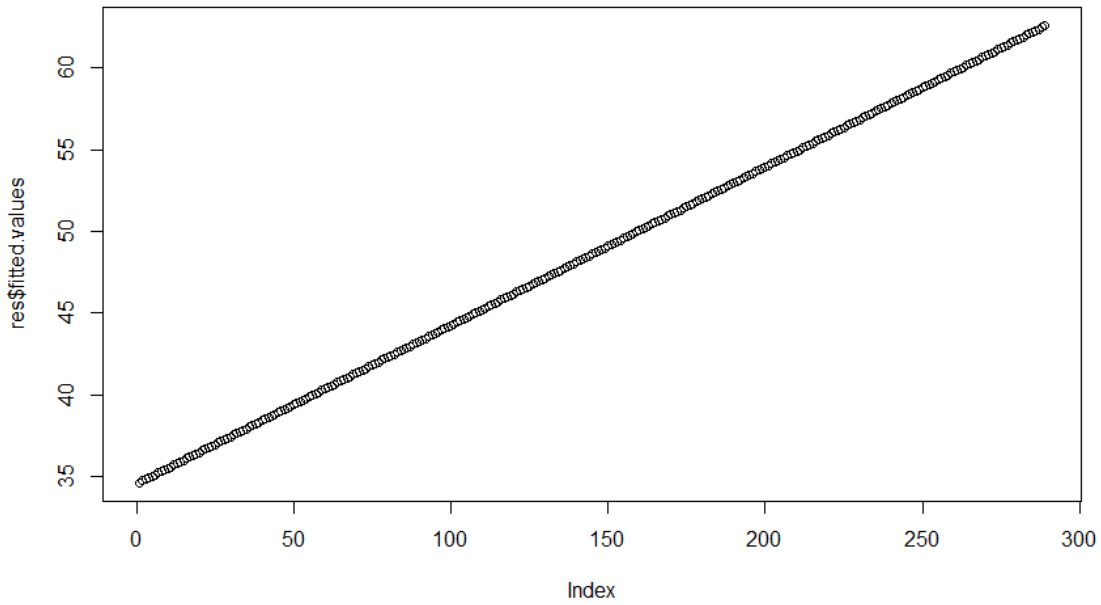

Восьмое задание:

Загрузите данные из файла пакета «UKgas.scv». Данные содержат объемы ежеквартально потребляемого газа в Великобритании с 1960 по 1986 гг. Постройте линейную регрессию для каждого квартала в отдельности и для всех кварталов вместе. Оцените, в каком квартале потребление газа имеет наибольшую и наименьшую динамику доходности. Сделайте прогноз по потреблению газа в 2016 году во всех кварталах и в среднем по году.

Код программы:

```
 library(datasets)
A <- read.csv("UKgas.csv")
i = 1
print(A[i,3])
A.1 <- cbind(A[i,3], A[i+1,3], A[i+2,3], A[i+3, 3])
i = 5
while(i < 108){
  Tmp <- cbind(A[i,3], A[i+1,3], A[i+2,3], A[i+3, 3])
  A.1 <- rbind(A.1, Tmp)
  i <- i + 4
}
A.1 <- data.frame(A.1, Year=1960:1986)
res<-lm(X1+X2+X3+X4~Year, data = A.1)
res1<-lm(X1~Year, data = A.1)
res2<-lm(X2~Year, data = A.1)
res3<-lm(X3~Year, data = A.1)
res4<-lm(X4~Year, data = A.1)
plot(res$fitted.values, x = (1960:1986))
lines(res1$fitted.values, col = "yellow", x = (1960:1986))
lines(res2$fitted.values, col = "blue", x = (1960:1986))
lines(res3$fitted.values, col = "green", x = (1960:1986))
lines(res4$fitted.values, col = "red", x = (1960:1986))
new<- data.frame(Year = (2016))
pred <- predict(res1, newdata = new )
print(pred)
plot(pred, x = (1980:2016))
```

Результаты:

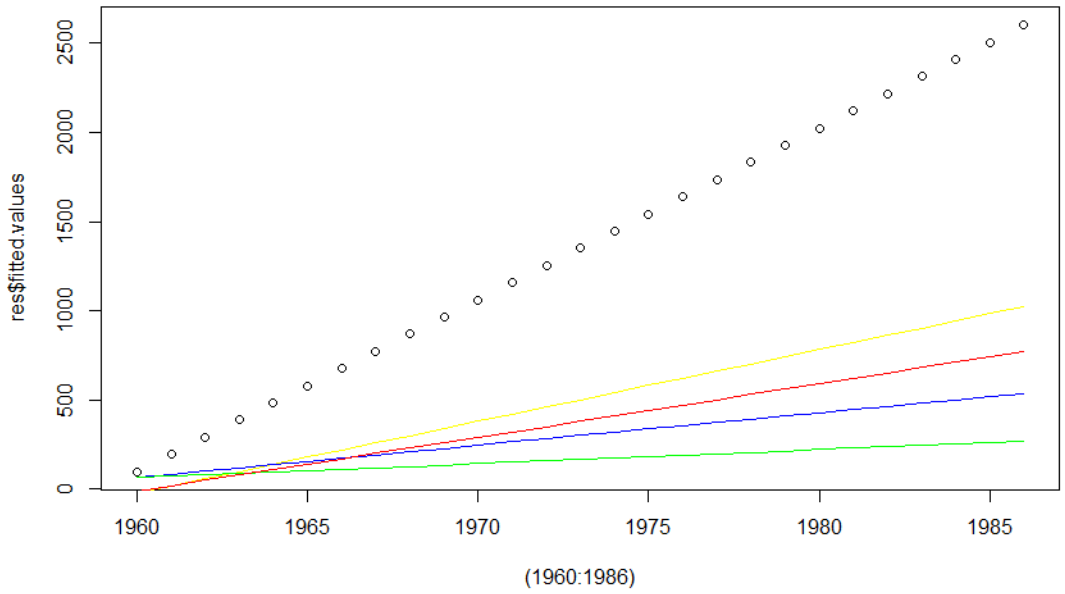

Предсказания:
1 квартал - 2230.936;
2 квартал - 1076.885;
3 квартал - 505.9368;
4 квартал - 1677.392;
Год - 5491.149;

Наиболее удовлетворительный первый квартал

Девятое задание:

Загрузите данные cars из пакета «datasets». Данные содержат зависимости тормозного пути автомобиля (футы) от его скорости (мили в час). Данные получены в 1920 г. Постройте регрессионную модель и оцените длину тормозного пути при скорости 40 миль в час.

Код программы:

```
library(datasets)
A <- cars
plot(A)
res<-lm(dist~speed, data = A)
plot(res$fitted.values)
new <-data.frame(speed=25:40)
dist <- c(predict(res,newdata = new))
new <- cbind(new, dist)
plot(new)
new2 <-data.frame(speed=40)
pred <- predict(res,newdata = new2)
print(pred)
```

Результаты:

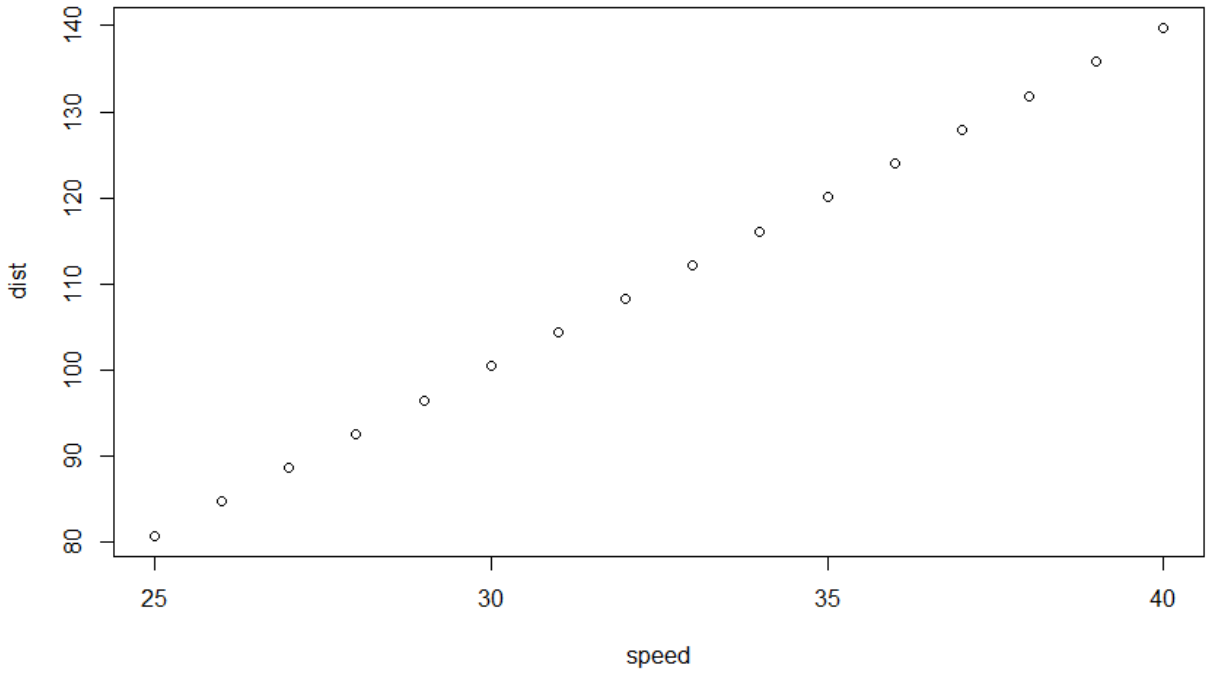

Длинна тормозного пути при 40 миль в час - 139.7173 футов.