Санкт-Петербургский политехнический университет Петра Великого
Институт компьютерных наук и технологий
Высшая школа программной инженерии

Лабораторная работа №7

“Бустинг”

по дисциплине “Машинное обучение”

Выполнил Лелюхин Д.О.

студент гр. 33504/2 _____

Руководитель Селин И.А.

_____

Санкт-Петербург

2018

Оглавление

Первое задание:

Исследуйте зависимость тестовой ошибки от количества деревьев в ансамбле для алгоритма adaboost.M1 на наборе данных Vehicle из пакета mlbench (обучающая выборка должна состоять из 7/10 всех прецедентов, содержащихся в данном наборе данных). Постройте график зависимости тестовой ошибки при числе деревьев, равном 1, 11, 21,…, 301, объясните полученные результаты.

Код программы:

```
#Unit 1
library(rpart)
library(mlbench)
library(adabag)
data(Vehicle)
l <- length(Vehicle[,1])
sub <- sample(1:l,l*(7/10))
mfinal <- 11
maxdepth <- 5
error <- c()
for(i in seq(1,301,by=10))
{
 Vehicle.adaboost <- boosting(Class ~.,data=Vehicle[sub,], mfinal=i, maxdepth=maxdepth)
 Vehicle.adaboost.pred <- predict.boosting(Vehicle.adaboost, newdata=Vehicle[-sub, ])
 print(Vehicle.adaboost.pred$error)
 error <- c(error,Vehicle.adaboost.pred$error)
}
plot(error, x = seq(1, 301, 10))
```

Результаты:

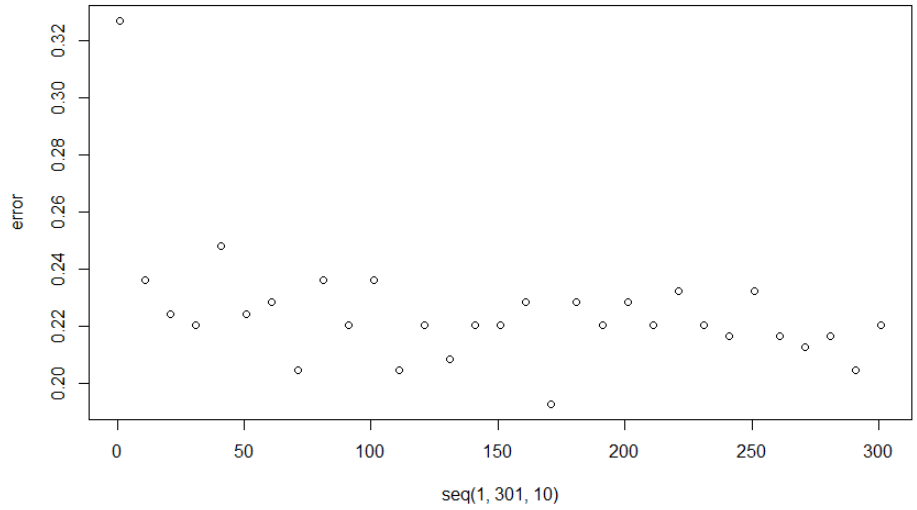

С увеличением максимального количества итераций количество ошибок уменьшается, но незначительно.

Второе задание:

Исследуйте зависимость тестовой ошибки от количества деревьев в ансамбле для алгоритма bagging на наборе данных Glass из пакета mlbench (обучающая выборка должна состоять из 7/10 всех прецедентов, содержащихся в данном наборе данных). Постройте график зависимости тестовой ошибки при числе деревьев, равном 1, 11, 21,…, 201, объясните полученные результаты.

Код программы:

```
library(mlbench)
library(adabag)
data(Glass)
l <- length(Glass[,1])
sub <- sample(1:l,l*(7/10))
mfinal <- 25
maxdepth <- 5
error <- c()
for(i in seq(1,201,by=10))
{
 Glass.bagging <- bagging(Type ~.,data=Glass[sub,], mfinal=i, maxdepth=5)
 Glass.bagging.pred <- predict.bagging(Glass.bagging, newdata=Glass[-sub, ])
 print(Glass.bagging.pred$error)
 error <- c(error,Glass.bagging.pred$error)
}
plot(error, x = seq(1, 201, 10))
```

Результаты:

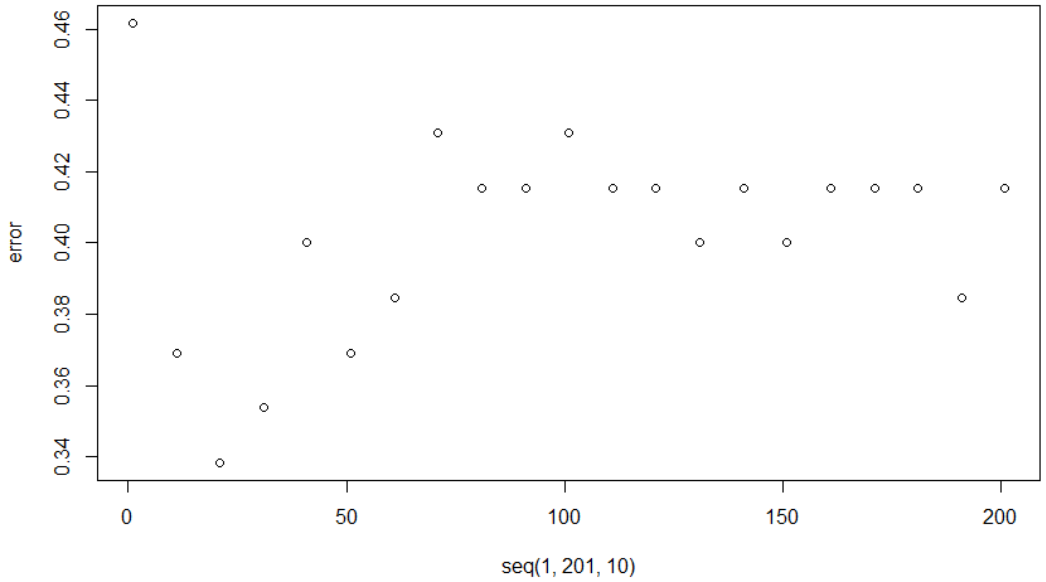

На графике видно, что ошибка с увеличением числа деревьев изменяется, но при количестве деревьев начиная с 71 изменения становятся не значительны.

Третье задание:

Реализуйте бустинг алгоритм с классификатором K ближайших соседей. Сравните тестовую ошибку, полученную с использованием данного классификатора на наборах данных Vehicle и Glass, с тестовой ошибкой, полученной с использованием единичного дерева классификации.

Код программы:

```
#Unit 3
learn = function(train, iter)
{
 error <- double(iter)
 i = 1
 classifiers <- list(iter)
 while (i < iter) {
  error[i] = 1
  while (error[i] > 0.1) {
   A_train = train
   n <- runif(1, 1, dim(A_train)[1])
   A_rand <- A_train[order(runif(n)),]
   tmp <- A_rand[1:n,]
   classifier <- kknn(Class ~ ., tmp, A_train)
   tb <- table(A_train$Class, classifier$fitted.values)
   error[i] <- 1 - (sum(diag(tb)) / sum(tb))
  }
  classifiers[i] = list(tmp)
  i = i + 1
 }
 return (classifiers)
}
run = function(frame, test)
{
 answer <- list(dim(test)[1] + 1)
 for (i in 1:length(frame)) {
  tmp <- kknn(Class ~ ., data.frame(frame[[i]]), test)
  answer[i] <- list(tmp$fitted.value)
 }
 prediction <- double(dim(test)[1])
 for (j in 1:dim(test)[1]) {
  check <- double(4)
  for (i in 1:length(answer))
  {
   check[answer[[i]][j]] = check[answer[[i]][j]] + 1
  }
  prediction[j] = levels(factor(test$Class))[which(check == max(check))]
 }
 tb <- table(test$Class, prediction)
 error <- 1 - (sum(diag(tb)) / sum(tb))
 return (error)
}
library(kknn)
library(mlbench)
library(rpart)
```

```
library(tree)
library(maptree)
library(caret)
library(adabag)
data(Vehicle)
l <- length(Vehicle[, 1])
sub <- sample(1:l, 2 * l / 3)
boost <- learn(Vehicle[sub, ], 20)
run(boost, Vehicle[-sub,])

Vehicle.rpart <- rpart(Class~.,data=Vehicle[sub,])
Vehicle.rpart.pred <- predict(Vehicle.rpart,newdata=Vehicle[-sub, ],type="class")
tb <- table(Vehicle.rpart.pred,Vehicle$Class[-sub])
error.rpart <- 1-(sum(diag(tb))/sum(tb))
print(error.rpart)
```

Результаты:

```
[1] 0.3368794
[1] 0.3865248
```

Расхождение в ошибках есть, но небольшое. Суть бустинга заключается в использовании слабых классификаторов. На мой взгляд использовать kknn в качестве классификатора для бустинга некорректно.